

■ 반복측정 분산분석(Repeated Measures ANOVA)

- 한 실험개체에서 2회 이상 측정을 수행하는 것
- 반복측정의 장점
 - 어떤 실험에서는 충분한 수의 실험개체를 확보하기 어려울 때 적용
 - 반복측정에서는 실험개체 스스로가 대조(control)의 역할을 함
 - ⇒ 실험개체가 블록이 됨
- 반복측정의 단점
 - 각 개체를 여러 번 실험처리하기 때문에 시간이 많이 소요
 - 이월효과(carry-over effect, 잔류효과)가 발생할 수 있음
 - ↳ 앞의 처리효과가 사라질 때까지 기다려야함
 - ↳ 기다려도 잔류효과 있을 수도!

□ 단일요인 반복측정 분산분석

- 반복측정 자료의 예 → 개체별노처리 (일변량)

개체	처리 1	처리 2	처리 3	처리 4
1	30	28	16	34
2	14	18	10	22
3	24	20	18	30
4	38	34	20	44
5	26	28	14	30
평균	26.4	25.6	15.6	32.0

○ 일변량 분산분석

● 통계모형

$$Y_{ij} = \mu + \underbrace{\rho_i}_{\text{개체효과}} + \underbrace{\tau_j}_{\text{처리(반복)}} + \varepsilon_{ij}, \quad \underbrace{i = 1, \dots, n_i}_{\text{개체}} \quad \underbrace{j = 1, \dots, p}_{\text{처리(반복)}}$$

○ ρ_i : 개체 i 의 효과(subject effect)

★ 동일한 개체의 자료들 간 상관관계가 존재할 수 있음

⇒ Y_{ij} 와 Y_{ik} 는 독립이라고 보기 어려움

⇒ ρ_i 는 랜덤효과(변량효과): $\rho_i \sim N(0, \sigma_s^2)$

↳ 고정효과로 둔다면 추정해야 할 개체가 커짐!

- 변동분해

$$\sum \sum (Y_{ij} - \bar{Y}_{..}) = 0$$

자유도 $np-1$

$$\sum (\bar{Y}_{i.} - \bar{Y}_{..}) = 0$$

자유도 $n-1$

$$\sum \sum (Y_{ij} - \bar{Y}_{i.}) = 0, \sum_j (Y_{ij} - \bar{Y}_{i.}) = 0$$

자유도 $np-n$

$$\sum \sum (Y_{ij} - \bar{Y}_{..})^2 = \sum \sum (\bar{Y}_{i.} - \bar{Y}_{..})^2 + \sum \sum (Y_{ij} - \bar{Y}_{i.})^2$$

TSS SSB SSW

- SSB(SS due to Between subject): 개체 간 제곱합
- SSW(SS due to Within subject): 개체 내 제곱합
- 개체 내 제곱합 분해

$$\sum \sum (Y_{ij} - \bar{Y}_{i.})^2 = \sum \sum (\bar{Y}_{.j} - \bar{Y}_{..})^2 + \sum \sum (Y_{ij} - \bar{Y}_{i.} - \bar{Y}_{.j} + \bar{Y}_{..})^2$$

SSW SSTR SSE

자유도 $np-n$

자유도 $p-1$

자유도 $(n-1)(p-1)$

- EMS

$$\oplus E(MSB) = \sigma^2 + p\sigma_s^2$$

$$\oplus E(MSTR) = \sigma^2 + n \sum \tau_j^2 / (p-1)$$

$$- E(MSE) = \sigma^2$$

$$\textcircled{1} E(SSB) = E[\sum (\bar{y}_{i.} - \bar{y}_{..})^2]$$

$$= E[\sum (\mu + \rho_i + \bar{e}_{i.}) - (\mu + \bar{\rho} + \bar{e}_{..})^2]$$

$$= E[\sum (\rho_i - \bar{\rho} + (\bar{e}_{i.} - \bar{e}_{..}))^2]$$

$$= E[\sum (\rho_i - \bar{\rho})^2] + E[\sum (\bar{e}_{i.} - \bar{e}_{..})^2]$$

$$= E[\rho \sum (\rho_i - \bar{\rho})^2] + (n-1)\sigma^2$$

$$= \rho(n-1)\sigma_s^2 + (n-1)\sigma^2$$

$$E(MSB) = E\left(\frac{SSB}{n-1}\right) = \frac{E(SSB)}{n-1} = \rho\sigma_s^2 + \sigma^2$$

$$\text{이때 } y_{ij} = \mu + \rho_i + \tau_i + e_{ij}$$

$$\bar{y}_{i.} = \frac{1}{p} \sum_j y_{ij} = \mu + \rho_i + 0 + \bar{e}_{i.}$$

$$\bar{y}_{..} = \frac{1}{np} \sum \sum y_{ij} = \mu + \bar{\rho} + 0 + \bar{e}_{..}$$

$$\textcircled{2} E(SSTR) = E[\sum (\bar{y}_{.j} - \bar{y}_{..})^2]$$

$$= E[\sum (\mu + \bar{\rho} + \tau_j + \bar{e}_{.j}) - (\mu + \bar{\rho} + \bar{e}_{..})^2]$$

$$= E[\sum (\tau_j + \bar{e}_{.j} - \bar{e}_{..})^2]$$

$$= E[\sum \tau_j^2] + E[\sum (\bar{e}_{.j} - \bar{e}_{..})^2]$$

$$= n \sum_j \tau_j^2 + (p-1)\sigma^2$$

$$\text{이때 } y_{ij} = \mu + \rho_i + \tau_j + e_{ij}$$

$$\bar{y}_{.j} = \frac{1}{n} \sum_i y_{ij} = \mu + \bar{\rho} + \tau_j + \bar{e}_{.j}$$

$$\bar{y}_{..} = \frac{1}{np} \sum \sum y_{ij} = \mu + \bar{\rho} + 0 + \bar{e}_{..}$$

$$E(MSTR) = E\left(\frac{SSTR}{p-1}\right) = \frac{E(SSTR)}{p-1} = \frac{n \sum_j \tau_j^2}{p-1} + \sigma^2$$

F가 왜 이런 형태?

: MSTR과 MSE를 비교하면 H_0, H_1 에 대한 목적 달성 가능!

- 가설검정

$\sum \tau_j^2 = 0,$

→ 하나라도 0이 아니면 $MSTR > MSE$

- $H_0 : \tau_1 = \tau_2 = \dots = \tau_p = 0$

- $$F = \frac{\frac{SSTR}{p-1}}{\frac{SSE}{(n-1)(p-1)}} = \frac{MSTR}{MSE} \sim F_{p-1, (n-1)(p-1)} \rightarrow \text{처리가의 효과검정}$$

⇒ 개체 간 변동에 영향을 받지 않고 순수하게 개체 내 변동만 평가하기 때문에 처리평균 간 비교를 정밀화할 수 있음

SSTR과 SSE가 SSW 내에서 이루어짐

SSW는 개체 내 제곱합

→ 개체간의 변동의 영향 X

벡터적인 방법으로 접근

Sigma matrix

$$\begin{matrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \dots & \text{Cov}(X_1, X_p) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & & \\ \vdots & \vdots & \ddots & \vdots \\ & \text{Cov}(X_p, X_{p-1}) & & \text{Var}(X_p) \end{matrix}$$

○ 다변량 분산분석과 자유도 수정

- 다변량적 접근방법 ^{두 단계}

$$Y_i = (Y_{i1}, Y_{i2}, \dots, Y_{ip})^T, \quad i = 1, \dots, n$$

- $Y_i \sim N_p(\mu, \Sigma)$, $\mu = (\mu_1, \mu_2, \dots, \mu_p)^T$
_{벡터가 normal}

- 공분산행렬 \rightarrow 2번 ^{대칭} $\left\{ \begin{matrix} \text{positive semidefinite (음의 X)} \end{matrix} \right.$

- 복합대칭성(compound symmetry)
_{= 구형성}

Σ matrix

$$\begin{pmatrix} \sigma_s^2 + \sigma^2 & \sigma_s^2 & \sigma_s^2 \\ \sigma_s^2 & \sigma_s^2 + \sigma^2 & \sigma_s^2 \\ \sigma_s^2 & \sigma_s^2 & \sigma_s^2 + \sigma^2 \end{pmatrix}$$

$$\sigma_{jk} = \text{Cov}(Y_{ij}, Y_{ik}) = \begin{cases} \sigma_s^2 + \sigma^2, & j = k \text{ ①} \\ \sigma_s^2, & j \neq k \text{ ②} \end{cases}$$

repeated measure model을
 다변량으로 접근? \rightarrow

- 일변량적 접근방법은 복합대칭성 또는 구형성(sphericity)과 같은 특수한 조건을 만족하는 경우 타당 \rightarrow 다변량과 같음 \equiv : 일변량 분산분석으로 진행

- 복합대칭성 또는 구형성 가정을 위배하는 경우 다변량 검정 또는 자유도 수정이 필요 (앞의 가정이 틀린 것이므로)

* 복합대칭성이 성립하는 경우

① diagonal ($j=k$)

$$\text{Cov}(Y_{ij}, Y_{ik}) = \text{Cov}(Y_{ij}, Y_{ij})$$

$$= \text{Var}(Y_{ij})$$

$$= \text{Var}(\mu + p_i + \tau_j + \epsilon_{ij})$$

$$= \text{Var}(p_i + \epsilon_{ij})$$

$$= \sigma_p^2 + \sigma^2 + 0$$

② not diagonal ($j \neq k$)

$$\text{Cov}(Y_{ij}, Y_{ik}) = \text{Cov}(\mu + p_i + \tau_j + \epsilon_{ij}, \mu + p_i + \tau_k + \epsilon_{ik})$$

$$= \text{Cov}(p_i, p_i)$$

$$= \text{Var}(p_i)$$

$$= \sigma_p^2$$

다변량 > 단변량 (아무때나 쓰면 안됨!) : 다변량이 더 broad한 개념!

↑ 공분산에 대한 가정 x

• 다변량 분산분석 (MANOVA, Multivariate ANOVA)

- $H_0 : \mu_1 = \mu_2 = \dots = \mu_p = 0$
- $\mu_j = \underbrace{\mu}_{\text{공통평균}} + \tau_j \Rightarrow H_0 : \underline{\tau} = 0 \rightarrow \begin{pmatrix} \tau_1 \\ \vdots \\ \tau_p \end{pmatrix} = \begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix}$

11/29

• Hotelling's T^2 통계량

- $W_i = (W_{i1}, \dots, W_{i,p-1})^T \equiv (Y_{i1} - Y_{ip}, \dots, Y_{i,p-1} - Y_{ip})^T$ 7번째 사량의
p번째 관측치

- $H_0 : \tau = 0 \Rightarrow H_0 : \mu_W = 0$

검정통계량 : $T^2 = n \bar{W}^T S_W^{-1} \bar{W}$ $\Rightarrow 1 \times (p-1) \cdot (p-1) \times (p-1) \cdot (p-1) \times 1 = 1 \times 1$ 차원 (스칼라)

$$S_W = \frac{1}{n-1} \sum_{i=1}^n (W_i - \bar{W})(W_i - \bar{W})^T$$

$\mathbb{R}^{(p-1) \times 1} \quad \mathbb{R}^{1 \times (p-1)}$

$$F_t = \frac{n-p+1}{(n-1)(p-1)} T^2 \sim F_{p-1, n-p+1}$$

$\Rightarrow (p-1) \times (p-1)$ 한 matrix를

componentwise 하게

$\frac{1}{n-1}$ 도 계산

$n \geq p$ 인 경우에만 적용가능

- 단변량 분모의 자유도 = $(n-1)(p-1)$

- 다변량 분모의 자유도 = $n - p + 1 < (n-1)(p-1)$

n 은 샘플수, p 는 차원수

고전통계학은 $n \geq p$ 라고 가정

최신통계학은 그렇지 않은 경우가 (ex. 유전학) \rightarrow 새로운 방법을 필요

분모의 자유도가 커질수록 꼬리쪽의 확률이 작아짐 (p-value가 커짐!)

\hookrightarrow 정리하면 $n < n(p-1)$

- 자유도 수정방법

↗ 다변량적 방법인 위키조건을 만족해야 쓸 수 있음

- 다변량적 방법에서는 공분산행렬에 대한 가정이 없음

⇒ 구형성 가정을 어느 정도 만족하는 경우 자유도 손실이 큼

- 자유도 수정계수 ϵ 이용

다변량적 방법을 쓸 수 없게 보지 않았음

- $\epsilon \in [0, 1]$

- $\epsilon \rightarrow 1$ 구형성 만족

- 복합대칭성(구형성) 가정 하에서 $F \sim F_{p-1, (n-1)(p-1)}$ ← 다변량

- 실제 F 는 $F_{\epsilon(p-1), \epsilon(n-1)(p-1)}$ 에 근사

- ϵ 의 추정

- Greenhouse and Geisser ϵ_{GG} Huynh and Feldt ϵ_{HF}

- $\epsilon_{GG} \leq \epsilon_{HF}$ ($\because \epsilon_{HF} = \min(\epsilon_{HF}, 1)$)

- ϵ 이 충분히 크면 일변량적 방법 이용

ex) $\epsilon_{GG} = 0.6049$ 라면?

→ 자유도 수정: $(p-1) \times 0.6049, (n-1)(p-1) \times 0.6049$

□ 다요인 반복측정 분산분석

○ 반복요인과 분류요인이 하나씩인 경우

● 반복측정 2요인 실험자료: 반복요인이 B인 경우 → 한개체에 대해 B를 여러번 반복

요인 A	개체	요인 B				평균
		1	2	3	4	
1	1	0	0	5	3	2.00
	2	3	1	5	4	4.25
	3	4	3	6	2	4.75
2	1	4	2	7	8	5.20
	2	5	4	6	6	5.20
	3	7	5	8	9	5.80
평균		3.83	2.50	6.17	5.33	4.46

○ 개체(subject)는 일종의 블록요인이고 요인 A에 지분되어(nested) 있음

● 통계모형식

$$Y_{ijk} = \mu + \alpha_j + \beta_k + (\alpha\beta)_{jk} + s_{i(j)} + \varepsilon_{ijk},$$

\uparrow i 가 j 에 nested
 $i = 1, \dots, s, j = 1, \dots, a, k = 1, \dots, b$
개체
요인A
요인B

Subject effect

- $s_{i(j)}$: 개체효과로 일반적으로 랜덤(변량)요인 → 추정해야 할 변수의 개수가 매우 늘어듬!
(분포에 관여하는 변수만 추정)
- $E(Y_{ijk}) = \mu + \alpha_j + \beta_k + (\alpha\beta)_{jk}$
- $Var(Y_{ijk}) = \sigma^2 + \sigma_s^2$
- $Cov(Y_{ijk}, Y_{ijk'}) = \sigma_s^2, \quad k \neq k'$
- $Cov(Y_{ijk}, Y_{i'j'k'}) = 0, \quad i \neq i' \text{ or/and } j \neq j'$

$$E(Y_{ijk}) = E(\mu + \alpha_j + \beta_k + (\alpha\beta)_{jk} + s_{i(j)} + \varepsilon_{ijk}) \rightarrow \text{random effect가 0}$$

$$Var(Y_{ijk}) = Var(\mu + \alpha_j + \beta_k + (\alpha\beta)_{jk} + s_{i(j)} + \varepsilon_{ijk})$$

↪ 상수니까 0

\downarrow
 σ_s^2 \downarrow
 σ^2

상수는 모두 0

요인B가
같지 않은 경우

$$\begin{aligned} Cov(Y_{ijk}, Y_{ijk'}) &= Cov(\mu + \alpha_j + \beta_k + (\alpha\beta)_{jk} + s_{i(j)} + \varepsilon_{ijk}, \mu + \alpha_j + \beta_{k'} + (\alpha\beta)_{jk'} + s_{i(j)} + \varepsilon_{ijk'}) \\ &= Cov(s_{i(j)} + \varepsilon_{ijk}, s_{i(j)} + \varepsilon_{ijk'}) = \sigma_s^2 + 0 + 0 + 0 = \sigma_s^2 \end{aligned}$$

$$\begin{aligned} Cov(Y_{ijk}, Y_{i'j'k'}) &= Cov(\mu + \alpha_j + \beta_k + (\alpha\beta)_{jk} + s_{i(j)} + \varepsilon_{ijk}, \mu + \alpha_{j'} + \beta_{k'} + (\alpha\beta)_{j'k'} + s_{i'(j')} + \varepsilon_{i'j'k'}) \\ &= Cov(s_{i(j)} + \varepsilon_{ijk}, s_{i'(j')} + \varepsilon_{i'j'k'}) = 0 + 0 + 0 + 0 = 0 \end{aligned}$$

\uparrow iid

● 변동분해

$$\text{TSS} = \underbrace{\text{SSA}}_{\text{SS}_{\text{between}}} + \overset{\text{nested}}{\text{SS}_{\text{subject(A)}}} + \underbrace{\text{SSB} + \text{SS(AB)}}_{\text{SS}_{\text{within}}} + \text{SSE}$$

i와 k에 대한 도가 모두 상하

$$\therefore \sum (\bar{Y}_{.j} - \bar{Y}_{...}) = 0$$

○ $\text{SSA} = \underbrace{bs}_{\text{이와 k에 대한 도가 모두 상하}} \sum_j (\bar{Y}_{.j} - \bar{Y}_{...})^2 : \underline{a-1} \Rightarrow E(\text{MSA}) = \sigma^2 + b\sigma_s^2 + bs \sum \alpha_j^2 / (a-1)$

○ $\text{SSB} = as \sum_k (\bar{Y}_{..k} - \bar{Y}_{...})^2 : b-1 \Rightarrow E(\text{MSB}) = \sigma^2 + as \sum \beta_k^2 / (b-1)$

○ $\text{SS(AB)} = s \sum_j \sum_k (\bar{Y}_{.jk} - \bar{Y}_{.j} - \bar{Y}_{..k} + \bar{Y}_{...})^2 : (a-1)(b-1)$

$(\bar{Y}_{.jk} - \bar{Y}_{...}) - (\bar{Y}_{.j} - \bar{Y}_{...}) - (\bar{Y}_{..k} - \bar{Y}_{...})$ $\Rightarrow E(\text{MS(AB)}) = \sigma^2 + s \sum_j \sum_k (\alpha\beta)_{jk}^2 / ((a-1)(b-1))$

○ $\text{SSS(A)} = \underline{b} \sum_i \sum_j (\bar{Y}_{ij.} - \bar{Y}_{.j.})^2 : a(s-1) \Rightarrow E(\text{MSS(A)}) = \sigma^2 + b\sigma_s^2$

○ $\text{SSE} = \sum_i \sum_j \sum_k (Y_{ijk} - \bar{Y}_{.jk} - \bar{Y}_{ij.} + \bar{Y}_{.j.})^2 : a(s-1)(b-1) \Rightarrow E(\text{MSE}) = \sigma^2$

나머지

$$(abs-1) - \frac{(a-1)}{\text{SSA}} - \frac{(b-1)}{\text{SSB}} - \frac{(a-1)(b-1)}{\text{SS(AB)}} - \frac{a(s-1)}{\text{SSS(A)}}$$

$ss_{\text{between}} = b \sum_j \sum_i (\bar{Y}_{ij.} - \bar{Y}_{.j.})^2 \rightarrow \text{자유도 } as-1$

$(as-1) - (a-1) = a(s-1)$

기타교사기억응답
다시듣기 - 11 -

$$E(SSA) = E \left[bs \sum_j (\bar{y}_{.j} - \bar{y}_{...})^2 \right]$$

$$= E \left[bs \sum_j \left((\mu + \alpha_j + \overline{S_{.j}} + \bar{\epsilon}_{.j}) - (\mu + \overline{S_{..}} + \bar{\epsilon}_{...}) \right)^2 \right]$$

$$= E \left[bs \sum_j (\alpha_j + \overline{S_{.j}} - \overline{S_{..}} + \bar{\epsilon}_{.j} - \bar{\epsilon}_{...})^2 \right]$$

$$= bs \sum_j \alpha_j^2 + b E \left[S \sum_j (\overline{S_{.j}} - \overline{S_{..}})^2 \right] + bs E \left[\sum_j (\bar{\epsilon}_{.j} - \bar{\epsilon}_{...})^2 \right]$$

$$= bs \sum_j \alpha_j^2 + b(a-1)\sigma_S^2 + (a-1)b\sigma^2$$

$$E(MSA) = E \left(\frac{SSA}{a-1} \right) = \frac{bs \sum \alpha_j^2}{a-1} + b\sigma_S^2 + \sigma^2$$

$$\text{이때 } y_{ijk} = \mu + \alpha_j + \beta_k + (\alpha\beta)_{jk} + S_{icj} + \epsilon_{ijk}$$

$$\bar{y}_{.j} = \frac{1}{ab} \sum_i \sum_k y_{ijk} = \mu + \alpha_j + 0 + 0 + \overline{S_{.j}} + \bar{\epsilon}_{.j}$$

$$\bar{y}_{...} = \frac{1}{abs} \sum_i \sum_j \sum_k y_{ijk} = \mu + 0 + 0 + 0 + \overline{S_{..}} + \bar{\epsilon}_{...}$$

$$\bar{y}_{..k} = \frac{1}{as} \sum_i \sum_j y_{ijk} = \mu + 0 + \beta_k + 0 + \overline{S_{..}} + \bar{\epsilon}_{..k}$$

$$\bar{y}_{.jk} = \frac{1}{s} \sum_i y_{ijk} = \mu + \alpha_j + \beta_k + (\alpha\beta)_{jk} + \overline{S_{.j}} + \bar{\epsilon}_{.jk}$$

$$\bar{y}_{ij.} = \frac{1}{b} \sum_k y_{ijk} = \mu + \alpha_j + 0 + 0 + S_{icj} + \bar{\epsilon}_{ij.}$$

12/4

$$E(SSB) = E \left[as \sum_k (\bar{y}_{..k} - \bar{y}_{...})^2 \right]$$

$$= E \left[as \sum_k \left((\mu + \beta_k + \overline{S_{..}} + \bar{\epsilon}_{..k}) - (\mu + \overline{S_{..}} + \bar{\epsilon}_{...}) \right)^2 \right]$$

$$= E \left[as \sum_k (\beta_k + \bar{\epsilon}_{..k} - \bar{\epsilon}_{...})^2 \right]$$

$$= E \left[as \sum_k \beta_k^2 \right] + E \left[as \sum_k (\bar{\epsilon}_{..k} - \bar{\epsilon}_{...})^2 \right]$$

$$= as \sum_k \beta_k^2 + (b-1)a\sigma^2$$

$$E(MSB) = E \left(\frac{SSB}{b-1} \right) = \frac{as \sum \beta_k^2}{b-1} + \sigma^2$$

$$E(SSS(A)) = E \left[b \sum_j \sum_k (\bar{y}_{ij.} - \bar{y}_{.j.})^2 \right]$$

$$= E \left[b \sum_j \sum_k \left((\mu + \alpha_j + S_{icj} + \bar{\epsilon}_{ij.}) - (\mu + \alpha_j + \overline{S_{.j}} + \bar{\epsilon}_{.j.}) \right)^2 \right]$$

$$= E \left[b \sum_j \sum_k (S_{icj} - \overline{S_{.j}} + \bar{\epsilon}_{ij.} - \bar{\epsilon}_{.j.})^2 \right]$$

$$= E \left[b \sum_j \sum_k (S_{icj} - \overline{S_{.j}})^2 \right] + E \left[b \sum_j \sum_k (\bar{\epsilon}_{ij.} - \bar{\epsilon}_{.j.})^2 \right]$$

$$= a(s-1)b\sigma_S^2 + (s-1)a\sigma^2$$

$$E(MSS(A)) = E \left(\frac{SSS(A)}{a(s-1)} \right) = b\sigma_S^2 + \sigma^2$$

$$E(SSAB) = E \left[s \sum_j \sum_k (\bar{y}_{.jk} - \bar{y}_{...})^2 \right]$$

$$= E \left[s \sum_j \sum_k \left((\mu + \alpha_j + \beta_k + (\alpha\beta)_{jk} + \overline{S_{.j}} + \bar{\epsilon}_{.jk}) - (\mu + \overline{S_{..}} + \bar{\epsilon}_{...}) \right)^2 \right]$$

$$= E \left[s \sum_j \sum_k (\alpha_j + \beta_k + (\alpha\beta)_{jk} + \overline{S_{.j}} - \overline{S_{..}} + \bar{\epsilon}_{.jk} - \bar{\epsilon}_{...})^2 \right]$$

$$= E \left[s \sum_j \sum_k \alpha_j^2 \right] + E \left[s \sum_j \sum_k \beta_k^2 \right] + E \left[s \sum_j \sum_k (\alpha\beta)_{jk}^2 \right] + E \left[s \sum_j \sum_k (\overline{S_{.j}} - \overline{S_{..}})^2 \right] + E \left[s \sum_j \sum_k (\bar{\epsilon}_{.jk} - \bar{\epsilon}_{...})^2 \right]$$

$$= sb \sum_j \alpha_j^2 + sa \sum_k \beta_k^2 + s \sum_j \sum_k (\alpha\beta)_{jk}^2 + b(a-1)\sigma_S^2 + (ab-1)\sigma^2$$

$$E \left[bs \sum_j (\overline{S_{.j}} - \overline{S_{..}})^2 \right]$$

$$= E \left[bs \sum_j (\overline{S_{.j}} - \overline{S_{..}})^2 \right], \text{ 이때 } \sum_j (\overline{S_{.j}} - \overline{S_{..}}) = 0 \text{ 자취도 } a-1$$

$$\sum_j \sum_k (\bar{\epsilon}_{.jk} - \bar{\epsilon}_{...}) = 0 \text{ 자취도 } ab-1$$

$$E(SS(AB)) = E(SSAB) - E(SSA) - E(SSB)$$

$$= sb \sum_j \alpha_j^2 + sa \sum_k \beta_k^2 + s \sum_j \sum_k (\alpha\beta)_{jk}^2 + b(a-1)\sigma_S^2 + (ab-1)\sigma^2 - (bs \sum_j \alpha_j^2 + b(a-1)\sigma_S^2 + (a-1)b\sigma^2) - (as \sum_k \beta_k^2 + (b-1)a\sigma^2)$$

$$= s \sum_j \sum_k (\alpha\beta)_{jk}^2 + (a-1)(b-1)\sigma^2$$

$$E(MS(AB)) = E \left(\frac{SS(AB)}{(a-1)(b-1)} \right) = \sigma^2 + \frac{s \sum_j \sum_k (\alpha\beta)_{jk}^2}{(a-1)(b-1)}$$

자취도의 합관계

$$ab-1-(a-1)-(b-1) = (a-1)(b-1)$$

$$* \text{MS(AB)의 자취도} = \text{MS(AB)의 자취도} - \text{MSA 자취도} - \text{MSB 자취도}$$

$$= \text{MS(AB) 자취도} - \text{MS(A) 자취도}$$

$$= ab(s-1) - (a-1) - (b-1) - (a-1)(b-1) - a(s-1)$$

$$= a(s-1)(b-1)$$

$$\text{MS(AB)의 기댓값} \rightarrow \sigma^2$$

* 무엇과 비교해야 내 목적을 위한 F를 만들 수 있는지를!

cf) $\hat{\sigma}_S^2 = ?$

$\frac{MSS(A) - MSE}{b}$ 이용

• 유의성검정

○ 요인 A의 주효과: $H_0 : \alpha_1 = \dots = \alpha_a = 0$

$$\left(\begin{array}{l} E(MSA) = \sigma^2 + b\sigma_s^2 + \frac{bs\sum \alpha_j^2}{a-1} \\ E(MSE) = \sigma^2 + b\sigma_s^2 \end{array} \right. F_A = \frac{SSA/(a-1)}{SS_{subject(A)}/(a(s-1))} \sim F_{a-1, a(s-1)}$$

○ 요인 B의 주효과: $H_0 : \beta_1 = \dots = \beta_b = 0$

$$\left(\begin{array}{l} E(MSB) = \sigma^2 + \frac{as\sum \beta_k^2}{b-1} \\ E(MSE) = \sigma^2 \end{array} \right. F_B = \frac{SSB/(b-1)}{SSE/(a(b-1)(s-1))} \sim F_{b-1, a(b-1)(s-1)}$$

○ 상호작용 (A*B)의 효과: $H_0 : (\alpha\beta)_{ij} = 0, \forall i, j$

$$F_{(AB)} = \frac{SS(AB)/(a-1)(b-1)}{SSE/(a(b-1)(s-1))} \sim F_{(a-1)(b-1), a(b-1)(s-1)}$$

$$\left(\begin{array}{l} E(MS(AB)) = \sigma^2 + \frac{s\sum \sum (\alpha\beta)_{jk}^2}{(a-1)(b-1)} \\ E(MSE) = \sigma^2 \end{array} \right.$$